

UNIVERSITÀ DEGLI STUDI DI MILANO
Facoltà di Scienze e Tecnologie
Corso di Laurea in Informatica (L-31)

ANALISI QUANTITATIVA E
PERCETTIVA DI VIDEO CREATI CON
GENERATORI AI

Relatore: Raffaella Lanza

Correlatore: Alessandro D'Amelio

Tesi di:
Federico COSCIA
Matricola: 977772

Anno Accademico 2023-2024

a Celestina

Indice

Introduzione	1
1 Generazione dei video fake	2
1.1 Funzionamento	2
1.2 Soluzioni attualmente disponibili	2
1.3 Video real	2
1.3.1 Scelta dei video real	2
1.3.2 Pre-Processing	2
1.4 Generazione dei video fake	2
2 Setting di acquisizione	3
2.1 Modalità di acquisizione	3
2.2 Estrazione delle feature	3
2.2.1 Video	3
2.2.2 Dati fisiologici	3
2.2.3 Eye-tracking	3
3 Protocollo sperimentale	4
3.1 Stesura del protocollo	4
3.1.1 Obiettivo	4
3.1.2 Disegno sperimentale	5
3.1.3 Variabili indipendenti	6
3.1.4 Variabili dipendenti	8
3.1.5 Definizione dei questionari	9
3.1.6 Dati fisiologici, Eye-tracker, FaceReader	10
3.1.7 Riassunto	11
3.2 Sviluppo dell'interfaccia	13
3.3 Salvataggio dei dati raccolti	13
4 Analisi dei dati acquisiti	14

Conclusioni	15
Bibliografia	16

Introduzione

Capitolo 1

Generazione dei video fake

1.1 Funzionamento

1.2 Soluzioni attualmente disponibili

1.3 Video real

1.3.1 Scelta dei video real

1.3.2 Pre-Processing

1.4 Generazione dei video fake

Capitolo 2

Setting di acquisizione

2.1 Modalità di acquisizione

2.2 Estrazione delle feature

2.2.1 Video

2.2.2 Dati fisiologici

2.2.3 Eye-tracking

Capitolo 3

Protocollo sperimentale

Per cominciare, è bene presentare il protocollo sperimentale che è stato definito, in quanto questo è il filo conduttore che lega tutto il progetto di ricerca di tesi. Il progetto è stato svolto in collaborazione con il dipartimento di Psicologia dell'Università Cattolica del Sacro Cuore, con il professore Andrea Gaggioli, il quale ha supervisionato e contribuito alla stesura del protocollo sperimentale e il processo di acquisizione dei dati, in particolar modo per la definizione dei vari questionari utilizzati. Inoltre, ha messo a disposizione la strumentazione di eye-tracking, la struttura e lo spazio utilizzati per lo svolgimento dell'esperimento di seguito costruito, e un team di tesisti che hanno collaborato alla stesura del protocollo e l'individuazione dei partecipanti.

3.1 Stesura del protocollo

3.1.1 Obiettivo

L'obiettivo di questo studio è confrontare l'esperienza di apprendimento per due contenuti didattici distinti, presentati in versioni con docenti reali o sintetici e in varianti maschili o femminili, per esplorare l'impatto delle variabili di presentazione e genere del docente, e del contenuto stesso, sulla qualità percepita dell'apprendimento e sulle risposte emotive e fisiologiche. Per fare questo, è stato ideato un esperimento fittizio, dove un campione di partecipanti volontari prende visione di alcuni contenuti didattici, e tramite la somministrazione di questionari di valutazione dell'esperienza visiva, la somministrazione di domande di comprensione, e la misura di diversi dati fisiologici misurati durante la visione, come il battito cardiaco, il movimento degli occhi e la sudorazione, viene misurata e valutata l'esperienza di visione dei video. A insaputa dei partecipanti, solo alcuni dei video mostrati sono reali, la restante parte è stata generata tramite IA. In questo capitolo affronteremo nel dettaglio come l'esperimento è stato disegnato e realizzato per ottenere i risultati migliori.

3.1.2 Disegno sperimentale

Per la somministrazione dei video reali e sintetici ai soggetti volontari sono stati valutati due tipi di disegni sperimentali. Supponiamo di aver individuato un campione, ad esempio di 30 partecipanti, disposti a partecipare al nostro esperimento, e di avere una raccolta di video didattici da dover mostrare, divisi fra reali e sintetici. Vogliamo garantire che i video reali e i video sintetici siano visualizzati in modo equo tra tutti i partecipanti, ma come suddividere le acquisizioni? Si presentano subito due opzioni:

1. Ogni partecipante visiona un solo video: i partecipanti vengono divisi in due gruppi, un gruppo visionerà i video reali e l'altro i video sintetici. Si tratta del disegno sperimentale *between-subject*
2. Tutti i partecipanti visionano due video: ogni partecipante visiona sia un video reale che uno sintetico. Non vi è quindi una divisione in gruppi, si tratta del disegno sperimentale *within-subject*

Between Subject

Nel disegno *between subject* i partecipanti vengono suddivisi in due gruppi, e ogni partecipante prende visione di un solo video. Un partecipante vedrà un video reale se appartiene al gruppo dei video reali, e un partecipante vedrà un video sintetico se appartiene al gruppo dei video sintetici. Questo disegno sperimentale comporta delle acquisizioni molto veloci, in quanto ogni partecipante deve visionare un solo video, ma comporta alcuni dettagli tecnici.

Dimensione del campione Questo disegno sperimentale richiede un campione di dimensioni doppie rispetto al *within-subject*. Dividendo il campione in due gruppi, se si vuole garantire che ogni tipo di video venga visionato n volte, è necessario trovare un campione grande $2n$.

Generalizzabilità dei risultati Inoltre, questo disegno sperimentale richiede un campione di maggiori dimensioni per poter garantire la generalizzabilità dei risultati. Con questo disegno sperimentale per ogni partecipante valutiamo solo come questo reagisce a un contenuto reale, se appartiene al gruppo dei video reali, o a un contenuto sintetico, se questo appartiene al gruppo dei video sintetici. Per poter generalizzare i risultati, per cui, è necessario un campione di grandi dimensioni, così da poter eliminare le differenze tra i singoli individui, e poter trarre delle conclusioni generali.

Un vantaggio, però, di cui si deve tener conto di questo disegno sperimentale, è che visionando un solo video lo spettatore non può avere influenze da altri video durante la visione, producendo i dati più puliti ed accurati.

Within Subject

Nel disegno within subject si elimina la suddivisione in gruppi, e a ogni partecipante sono mostrati due video. I due video mostrati sono sempre uno reale e uno sintetico. Secondo questo disegno le acquisizioni richiedono più tempo da parte dei partecipanti, ma così facendo, si dimezza la dimensione del campione richiesta, in quanto ogni partecipante vede entrambi i tipi di video, e inoltre riduce il problema della generalizzabilità. Mostrando ad ogni partecipante sia un video reale che un video sintetico, è possibile misurare come la stessa persona reagisce ai due contenuti di natura diversa. Questo è importante in quanto uno stesso video può avere effetti ben diversi su persone diverse (CITATION NEEDED). Questo permette di ottenere risultati generalizzabili prima. Al contrario del between-subject, però, visionando due video la percezione del secondo video potrebbe essere influenzata dal primo video.

La scelta

In luce di queste osservazioni, è stato scelto il design *within-subject*. Ogni partecipante per cui visiona due video, di cui sempre uno reale e uno sintetico.

3.1.3 Variabili indipendenti

Stabilito il disegno sperimentale, sono state individuate le variabili dipendenti e indipendenti. Oltre alla natura del video (reale o sintetico), c'è da tenere conto anche del genere del docente, in quanto, per come già trovato da ... CITATION NEEDED ..., il genere può avere un'influenza sull'esperienza di visione dei video, a seconda dello spettatore, per cui dobbiamo tenerne conto, e assicurarci che nel corso dell'esperimento non vi sia una predominanza di un genere sull'altro nei video mostrati. Inoltre, dal momento che abbiamo bisogno di mostrare due video, e non possiamo certamente mostrare lo stesso video due volte (CITATION NEEDED), abbiamo bisogno di due contenuti diversi che i docenti andranno a trattare nei video. Riassumendo, le variabili indipendenti in gioco che determinano il tipo di video che un partecipante può andare a vedere sono:

- Tipo di contenuto:
 - Contenuto A
 - Contenuto B
- Tipo di Presentatore:
 - Reale (docente videoregistrato)
 - Sintetico (personaggio generato da AI)

Partecipante	Contenuto Video 1	Tipo Video 1	Genere Video 1	Contenuto Video 2	Tipo Video 2	Genere Video 2
1	A	Sintetico	Maschile	B	Reale	Femminile
2	A	Reale	Maschile	B	Sintetico	Femminile
3	B	Sintetico	Maschile	A	Reale	Femminile
4	B	Reale	Maschile	A	Sintetico	Femminile
5	A	Sintetico	Femminile	B	Reale	Maschile
6	A	Reale	Femminile	B	Sintetico	Maschile
7	B	Sintetico	Femminile	A	Reale	Maschile
8	B	Reale	Femminile	A	Sintetico	Maschile
9	A	Sintetico	Maschile	B	Reale	Femminile
10	A	Reale	Maschile	B	Sintetico	Femminile
11	B	Sintetico	Maschile	A	Reale	Femminile
12	B	Reale	Maschile	A	Sintetico	Femminile
13	A	Sintetico	Femminile	B	Reale	Maschile
14	A	Reale	Femminile	B	Sintetico	Maschile
15	B	Sintetico	Femminile	A	Reale	Maschile
16	B	Reale	Femminile	A	Sintetico	Maschile

Tabella 1: Matrice sperimentale (ipotizzando un campione di 16 partecipanti)

- Genere del Presentatore:
 - Maschile
 - Femminile

Ogni possibile combinazione di assegnamenti di queste tre variabili rappresenta un possibile video che un partecipante può visionare. Ad esempio, un assegnamento del tipo:

$$Contenuto1 = A \wedge Tipo1 = Reale \wedge Genere1 = Maschile$$

rappresenta un video reale con un docente di genere maschile che espone il contenuto A. Sulla base di queste variabili andiamo a costruire una matrice sperimentale, ovvero una matrice che specifica, per ogni partecipante, il valore di ognuna di queste variabili per il primo e il secondo video che i partecipanti andranno a visionare durante l'esperimento, specificando di conseguenza i due video che ogni partecipante andrà a visionare. Osserviamo che le tre variabili sono tutte e tre variabili binarie, ovvero possono assumere solo due valori. Questo ci permette di definire estremamente facilmente il vincolo che lega il primo e il secondo video: il secondo video sarà la negazione logica

del primo, dove se $Contenuto1$, $Tipo1$, e $Genere1$ sono le variabili che specificano il contenuto, il tipo e il genere del primo video, per il secondo video le variabili associate assumeranno rispettivamente i valori $Contenuto2 = \overline{Contenuto1}$, $Tipo2 = \overline{Tipo1}$ e $Genere2 = \overline{Genere1}$. Per cui, ad esempio, sulla base dell'assegnamento indicato in precedenza, il secondo video sarebbe definito dai valori:

$$Contenuto2 = B \wedge Tipo2 = Sintetico \wedge Genere2 = Femminile$$

Per costruire la matrice è sufficiente esplicitare tutte le possibili combinazioni di assegnamenti di queste tre variabili per il primo video, e per ogni combinazione ricavare i rispettivi valori per il secondo video, utilizzando il vincolo appena definito. Esplicitando tutte le possibili combinazioni garantiamo che, con un campione abbastanza grande, tutti i casi possibili sono coperti e non vi sono combinazioni predominanti che potrebbero sbilanciare i dati raccolti. Osserviamo che le variabili sono tre, per cui il numero di possibili combinazioni è di $2^3 = 8$, per cui dopo 8 partecipanti la matrice si ripeterà, si tratta quindi di una matrice periodica. È possibile vedere un'esempio di questa matrice in Tabella 1, dato un campione di 16 partecipanti. È possibile notare la periodicità della tabella, dove i valori delle variabili per i partecipanti da 1 a 8 sono ripetuti per i partecipanti da 9 a 16. Si osservi che non è importante la combinazione di partenza, posto che il campione sia abbastanza grande da coprire tutte le possibili combinazioni. Per stabilire la dimensione del campione, infine, è sufficiente stabilire quante volte si desidera coprire tutte le combinazioni, e scegliere una dimensione appropriata. Ad esempio, se si vuole coprire tutti i casi possibili almeno cinque volte, servirà un campione di almeno $5 \cdot 8 = 32$ partecipanti.

3.1.4 Variabili dipendenti

In un esperimento, una variabile dipendente è una variabile che viene osservata e misurata, per studiare l'effetto causato da variazioni alle variabili indipendenti su tale variabile. Nel nostro caso, si tratta di cosa può influenzare in uno spettatore la natura sintetica di un video. Le variabili dipendenti identificate sono:

- Esperienza emotiva durante la lezione (misurata con questionari psicometrici post-sessione)
- Qualità dell'apprendimento (misurata con test di comprensione post-sessione)
- Fissazioni e movimento dello sguardo (misurati con eye-tracker)
- Frequenza cardiaca e livello di sudorazione (misurati tramite sensore sul polso)
- Espressioni emotive facciali (monitorate tramite registrazione della webcam)

Per la misurazione delle prime due variabili è stato necessario definire i questionari da somministrare durante l'esperimento.

3.1.5 Definizione dei questionari

I questionari sono stati definiti dal professore Andrea Gaggioli del dipartimento di Psicologia dell'Università Cattolica del Sacro Cuore.

Questionari pre-trattamento

Sono stati specificati dei questionari pre-trattamento, da somministrare ai partecipanti all'inizio dell'esperimento, prima della visione di qualsiasi video. Qui vengono raccolti semplici dati demografici come l'età, il genere, la nazionalità e il livello di istruzione di ogni partecipante. In seguito, è somministrato un questionario di autovalutazione del loro stato emotivo pre-trattamento, seguito da una domanda (in una scala da 1 a 5) sulla quanto frequentemente il partecipante fa utilizzo di contenuti multimediali per l'apprendimento. Più nello specifico, i questionari pre-trattamento consistono in, in questo ordine:

- Dati demografici (età, genere, nazionalità, livello di istruzione)
- Questionario per valutare lo stato emotivo iniziale (Positive and Negative Affect Schedule - PANAS), che misura l'umore momentaneo
- Scala sulla frequenza di utilizzo di contenuti video per l'apprendimento (ad es., lezioni online, tutorial, corsi su piattaforme digitali).

Questionari post-video

In seguito, sono previsti dei questionari a seguito di ognuno dei due video. I questionari post-video consistono in un'autovalutazione del proprio stato emotivo in seguito alla visione, delle domande (in una scala da 1 a 5) sulla percezione della qualità dell'apprendimento e sulla valutazione del presentatore. Infine, è prevista una breve sessione di domande di comprensione a risposta multipla sui contenuti trattati nel video appena visionato, per misurare il grado di comprensione raggiunto. In un elenco puntato, i questionari post-video consistono in, in questo ordine:

- Esperienza emotiva: Positive and Negative Affect Schedule (PANAS), per misurare i sentimenti positivi e negativi provati durante la videolezione
- Percezione della qualità dell'apprendimento:
 1. *"Quanto hai trovato chiari i contenuti della lezione?"* (scala da 1 a 5)

2. *"Quanto sono stati facili da comprendere i concetti presentati nella lezione?"* (scala da 1 a 5)
 3. *"Quanto hai trovato ben organizzata la presentazione dei contenuti?"* (scala da 1 a 5)
 4. *"Quanto pensi di aver appreso dai contenuti presentati?"* (scala da 1 a 5)
 5. *"Quanto ti senti sicuro/a di ricordare le informazioni apprese nella lezione?"* (scala da 1 a 5)
 6. *"Quanto ti senti preparato/a ad applicare i concetti appresi?"* (scala da 1 a 5)
 7. *"Quanto ritieni utile la lezione per il tuo apprendimento?"* (scala da 1 a 5)
 8. *"Quanto la lezione ha stimolato il tuo interesse per l'argomento?"* (scala da 1 a 5)
 9. *"Quanto ti senti motivato/a a saperne di più sull'argomento dopo aver visto la lezione?"* (scala da 1 a 5)
- Valutazione del presentatore
 1. *"Come descriveresti il modo di presentare del relatore?"* (scala da 1 a 5, dove 1 è "Molto impersonale" e 5 è "Molto coinvolgente")
 2. *"Quanto hai trovato efficace il relatore nella trasmissione dei contenuti?"* (scala da 1 a 5)
 3. *"Quanto ti è sembrato chiaro e sicuro il relatore durante la spiegazione?"* (scala da 1 a 5)
 4. *"Quanto ti sei sentito/a in sintonia con il relatore?"* (scala da 1 a 5)
 5. *"Quanto il presentatore ti è sembrato naturale e realistico nella presentazione dei contenuti?"* (scala da 1 a 5)
 - Test di comprensione per valutare l'apprendimento oggettivo

I test di comprensione per valutare l'apprendimento oggettivo consistono in un quiz da 3 domande a crocette, con 1 risposta giusta e 2 risposte sbagliate, sui contenuti trattati.

3.1.6 Dati fisiologici, Eye-tracker, FaceReader

Per la cattura e il monitoraggio delle variabili dipendenti durante l'esperimento quali il battito cardiaco, la sudorazione, il movimento dello sguardo e le espressioni facciali, sono stati predisposti diversi strumenti di cattura.

Dati fisiologici

Per la cattura dei dati fisiologici, ovvero il battito cardiaco e il livello di sudorazione della pelle, è stato predisposto un braccialetto Embrace Plus di Empatica Inc., indossato sul polso della mano non dominante di ogni partecipante. Il braccialetto permette di misurare non intrusivamente i segnali che ci interessano. Tra questi, il livello di sudorazione della pelle, detto anche Electrodermal Activity (EDA), è particolarmente importante, in quanto questo è fortemente collegato ai livelli di stress, tensione e reazione emotiva, specie durante l'apprendimento [1][2]. Per assicurarsi una lettura accurata dei dati richiesti, i partecipanti sono richiesti di indossare il braccialetto per 5-10 minuti prima dell'inizio dell'esperimento, affinché la pelle del partecipante possa abituarsi al contatto con il sensore, e fornire una lettura accurata dei livelli di sudorazione, come indicato dai manuali d'uso di Empatica. Il braccialetto è configurato e abilitato via applicazione via smartphone, e i dati sono salvati su un server Amazon AWS, da cui è possibile scaricare offline in qualsiasi momento tutti i dati raccolti.

Eye-tracker

Per il tracciamento dello sguardo e la misura delle fissazioni è utilizzato l'eye-tracker EyeLink 1000, di SR Research Ltd. Per l'utilizzo dell'eye-tracker è prevista una fase di calibrazione, svolta manualmente da un operatore, insieme al partecipante, prima di avviare l'esperimento. In seguito, l'eye-tracker è pilotato dal computer che guida il partecipante attraverso l'esperimento, per cui il tracciamento e il salvataggio dei dati raccolti è automatico.

Espressioni facciali

Per catturare le espressioni facciali, il partecipante viene registrato per tutta la durata dell'esperimento, previo consenso esplicito, tramite webcam posta sullo schermo sul quale vengono visualizzati i video. In seguito, le espressioni facciali e le emozioni associate vengono estratte dal video registrato utilizzando la libreria di python PyFeat. Come trovato da [3][4], le espressioni facciali, e le relative emozioni, sono un buon indicatore del livello di interesse e coinvolgimento di uno studente durante l'apprendimento.

3.1.7 Riassunto

Per riassumere, il disegno è di tipo *within-subjects*. Ciascun partecipante visiona due video didattici:

- Uno recitato da un docente maschio e uno da una docente femmina.

- Uno in versione reale (docente videoregistrato) e uno in versione sintetica (generato dall'AI).

Le variabili indipendenti sono:

- Tipo di contenuto:
 - Contenuto A
 - Contenuto B
- Tipo di Presentatore:
 - Reale (docente videoregistrato)
 - Sintetico (personaggio generato da AI)
- Genere del Presentatore:
 - Maschile
 - Femminile

Mentre le variabili dipendenti sono:

- Esperienza emotiva durante la lezione (misurata con questionari psicometrici post-sessione).
- Qualità dell'apprendimento (misurata con test di comprensione post-sessione).
- Eye tracking (misure di fissazione e sguardo).
- Frequenza cardiaca e sudorazione (misurate con braccialetto munito di sensore).
- Espressioni emotive facciali (analizzate tramite registrazione della webcam ed estratte con la libreria Python PyFeat).

Prima di cominciare, i partecipanti vengono accolti, e viene richiesta la firma del consenso informato sulla cattura di tutti i dati sopra indicati. I partecipanti non sono informati della natura reale o sintetica dei personaggi nei video, per evitare bias sui dati raccolti. Prima di avviare l'esperimento, è prevista la preparazione delle misure fisiologiche:

- Battito cardiaco e sudorazione: Applicazione del braccialetto.
- Eye tracking: Calibrazione delle misure oculari.

- Espressioni facciali: Posizionamento della videocamera per il monitoraggio delle espressioni facciali.

Ogni partecipante visiona due video con contenuti diversi. Ciascun contenuto è presentato in una combinazione unica di caratteristiche: un contenuto sarà presentato da un docente maschile e l'altro da una docente femminile, uno sarà in versione reale e l'altro in versione sintetica. Il controbilanciamento copre anche l'ordine tra contenuto, genere e tipo di presentatore. Al termine, i partecipanti sono informati sui veri scopi dell'esperimento e sull'utilizzo dei dati raccolti.

3.2 Sviluppo dell'interfaccia

3.3 Salvataggio dei dati raccolti

Capitolo 4

Analisi dei dati acquisiti

Conclusioni

Bibliografia

- [1] Elena Di Lascio, Shkurta Gashi, and Silvia Santini. Unobtrusive assessment of students' emotional engagement during lectures using electrodermal activity sensors. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2(3):1–21, 2018.
- [2] Angelica M Tinga, Tycho T De Back, and Max M Louwerse. Non-invasive neurophysiology in learning and training: mechanisms and a swot analysis. *Frontiers in neuroscience*, 14:589, 2020.
- [3] Jacob Whitehill, Zewelangi Serpell, Yi-Ching Lin, Aysha Foster, and Javier R Movellan. The faces of engagement: Automatic recognition of student engagement-from facial expressions. *IEEE Transactions on Affective Computing*, 5(1):86–98, 2014.
- [4] Zhaoli Zhang, Zhenhua Li, Hai Liu, Taihe Cao, and Sannyuya Liu. Data-driven online learning engagement detection via facial expression and mouse behavior recognition technology. *Journal of Educational Computing Research*, 58(1):63–86, 2020.

Ringraziamenti