

UNIVERSITÀ DEGLI STUDI DI MILANO
Facoltà di Scienze e Tecnologie
Corso di Laurea in Informatica (L-31)

ANALISI QUANTITATIVA E
PERCETTIVA DI VIDEO CREATI CON
GENERATORI AI

Relatore: Raffaella Lanza

Correlatore: Alessandro D'Amelio

Tesi di:
Federico COSCIA
Matricola: 977772

Anno Accademico 2023-2024

a Celestina

Indice

Introduzione	1
1 Generazione dei video fake	2
1.1 Funzionamento	2
1.2 Soluzioni attualmente disponibili	2
1.3 Video real	2
1.3.1 Scelta dei video real	2
1.3.2 Pre-Processing	2
1.4 Generazione dei video fake	2
2 Setting di acquisizione	3
2.1 Modalità di acquisizione	3
2.2 Estrazione delle feature	3
2.2.1 Video	3
2.2.2 Dati fisiologici	3
2.2.3 Eye-tracking	3
3 Protocollo sperimentale	4
3.1 Stesura del protocollo	4
3.1.1 Obiettivo	4
3.1.2 Disegno sperimentale	5
3.1.3 Variabili indipendenti	6
3.1.4 Variabili dipendenti	8
3.1.5 Definizione dei questionari	9
3.1.6 Dati fisiologici, sguardo, espressioni facciali	13
3.1.7 Riepilogo	15
3.2 Sviluppo dell'interfaccia	16
3.2.1 Design di sviluppo	16
3.2.2 Avvio dell'esperimento	17
3.2.3 Raccolta dei timestamp	17
3.2.4 Registrazione della webcam/dello schermo	18

3.2.5	Controllo dell'eye-tracker	19
3.3	Salvataggio dei dati raccolti	20
3.3.1	Salvataggio dei dati demografici e delle risposte	20
3.3.2	Salvataggio delle registrazioni video	20
3.3.3	Salvataggio dei dati di eye-tracking	20
3.3.4	Salvataggio dei dati fisiologici	21
4	Analisi dei dati acquisiti	23
	Conclusioni	24
	Bibliografia	25

Introduzione

Capitolo 1

Generazione dei video fake

1.1 Funzionamento

1.2 Soluzioni attualmente disponibili

1.3 Video real

1.3.1 Scelta dei video real

1.3.2 Pre-Processing

1.4 Generazione dei video fake

Capitolo 2

Setting di acquisizione

2.1 Modalità di acquisizione

2.2 Estrazione delle feature

2.2.1 Video

2.2.2 Dati fisiologici

2.2.3 Eye-tracking

Capitolo 3

Protocollo sperimentale

Per cominciare, è bene presentare il protocollo sperimentale che è stato definito, in quanto questo è il filo conduttore che lega tutto il progetto di ricerca di tesi. Il progetto è stato svolto in collaborazione con il dipartimento di Psicologia dell'Università Cattolica del Sacro Cuore, con il professore Andrea Gaggioli, il quale ha supervisionato e contribuito alla stesura del protocollo sperimentale e il processo di acquisizione dei dati, in particolar modo per la definizione dei vari questionari utilizzati. Inoltre, ha messo a disposizione la strumentazione di eye-tracking, la struttura e lo spazio utilizzati per lo svolgimento dell'esperimento di seguito descritto, e un team di tesisti che hanno collaborato alla stesura del protocollo e l'individuazione dei partecipanti.

3.1 Stesura del protocollo

3.1.1 Obiettivo

L'obiettivo di questo studio è confrontare l'esperienza di apprendimento per due contenuti didattici distinti, presentati in versioni con docenti reali o sintetici e in varianti maschili o femminili, per esplorare l'impatto delle variabili di presentazione e genere del docente, e del contenuto stesso, sulla qualità percepita dell'apprendimento e sulle risposte emotive e fisiologiche. Per fare questo, è stato ideato un esperimento, dove un campione di partecipanti volontari prende visione di alcuni contenuti didattici, e tramite la somministrazione di questionari di valutazione dell'esperienza visiva, la somministrazione di domande di comprensione, e la misura di diversi dati fisiologici misurati durante la visione, come il battito cardiaco, il movimento degli occhi e la sudorazione, viene misurata e valutata l'esperienza di visione dei video. A insaputa dei partecipanti, solo alcuni dei video mostrati sono reali, la restante parte è stata generata tramite IA. In questo capitolo affronteremo nel dettaglio come l'esperimento è stato disegnato e realizzato per ottenere i risultati migliori.

3.1.2 Disegno sperimentale

Per la somministrazione dei video reali e sintetici ai soggetti volontari sono stati valutati due tipi di disegni sperimentali. Supponiamo di aver individuato un campione, ad esempio di 30 partecipanti, disposti a partecipare al nostro esperimento, e di avere una raccolta di video didattici da dover mostrare, divisi fra reali e sintetici. Vogliamo garantire che i video reali e i video sintetici siano visualizzati in modo equo tra tutti i partecipanti, ma come suddividere le acquisizioni? Si presentano subito due opzioni:

1. Ogni partecipante visiona un solo video: i partecipanti vengono divisi in due gruppi, un gruppo visionerà i video reali e l'altro i video sintetici. Si tratta del disegno sperimentale *between-subject*
2. Tutti i partecipanti visionano due video: ogni partecipante visiona sia un video reale che uno sintetico. Non vi è quindi una divisione in gruppi, si tratta del disegno sperimentale *within-subject*.

Between Subject

Nel disegno *between subject* i partecipanti vengono suddivisi in due gruppi, e ogni partecipante prende visione di un solo video. Un partecipante vedrà un video reale se appartiene al gruppo dei video reali, mentre un partecipante vedrà un video sintetico se appartiene al gruppo dei video sintetici. Questo disegno sperimentale comporta delle acquisizioni molto veloci, in quanto ogni partecipante deve visionare un solo video, ma comporta alcuni dettagli tecnici.

Dimensione del campione Questo disegno sperimentale richiede un campione di dimensioni doppie rispetto al *within-subject*. Dividendo il campione in due gruppi, se si vuole garantire che ogni tipo di video venga visionato n volte, è necessario trovare un campione grande $2n$.

Generalizzabilità dei risultati Inoltre, questo disegno sperimentale richiede un campione di maggiori dimensioni per poter garantire la generalizzabilità dei risultati. Con questo disegno sperimentale per ogni partecipante valutiamo solo come questo reagisce a un contenuto reale, se appartiene al gruppo dei video reali, o a un contenuto sintetico, se questo appartiene al gruppo dei video sintetici. Per poter generalizzare i risultati, per cui, è necessario un campione di grandi dimensioni, così da poter eliminare le differenze tra i singoli individui, e poter trarre delle conclusioni generali.

Un vantaggio, però, di cui si deve tener conto di questo disegno sperimentale, è che visionando un solo video lo spettatore non può avere influenze da altri video durante la visione, producendo i dati più puliti ed accurati.

Within-Subject

Nel disegno within subject si elimina la suddivisione in gruppi, e a ogni partecipante sono mostrati due video, uno reale e uno sintentico. L'ordine di visione è bilanciato tra tutti i partecipanti, alternando quale viene visionato per primo, in modo da eliminare un possibile bias dovuto all'ordine di visione. L'ordine può anche essere stabilito in modo casuale, avendo un campione di grandi dimensioni che permette la distribuzione uniforme dei due casi. È possibile vedere al Paragrafo 3.1.3 un esempio di come questo ordine può essere stabilito in base al numero del partecipante. Secondo questo disegno le acquisizioni richiedono più tempo da parte dei partecipanti, ma così facendo, si dimezza la dimensione del campione richiesta, in quanto ogni partecipante vede entrambi i tipi di video, e inoltre riduce il problema della generalizzabilità. Mostrando ad ogni partecipante sia un video reale che un video sintetico, è possibile misurare come la stessa persona reagisce ai due contenuti di natura diversa. Questo è importante in quanto uno stesso video può avere effetti ben diversi su persone diverse (CITATION NEEDED). Questo permette di ottenere risultati generalizzabili prima. Al contrario del between-subject, però, visionando due video la percezione del secondo video potrebbe essere influenzata dal primo video.

La scelta

In luce di queste osservazioni, è stato scelto il design *within-subject*. Ogni partecipante per cui visiona due video, di cui sempre uno reale e uno sintetico.

3.1.3 Variabili indipendenti

Stabilito il disegno sperimentale, sono state individuate le variabili dipendenti e indipendenti. Oltre alla natura del video (reale o sintetico), c'è da tenere conto anche del genere del docente, in quanto, per come già trovato da ... CITATION NEEDED ..., il genere può avere un'influenza sull'esperienza di visione dei video, a seconda dello spettatore, per cui dobbiamo tenerne conto, e assicurarci che nel corso dell'esperimento non vi sia una predominanza di un genere sull'altro nei video mostrati. Inoltre, dal momento che abbiamo bisogno di mostrare due video, e non possiamo certamente mostrare lo stesso video due volte (CITATION NEEDED), abbiamo bisogno di due contenuti diversi che i docenti andranno a trattare nei video. Riassumendo, le variabili indipendenti in gioco che determinano il tipo di video che un partecipante può andare a vedere sono:

- Tipo di contenuto:
 - Contenuto A
 - Contenuto B

Partecipante	Contenuto Video 1	Tipo Video 1	Genere Video 1	Contenuto Video 2	Tipo Video 2	Genere Video 2
1	A	Sintetico	Maschile	B	Reale	Femminile
2	A	Reale	Maschile	B	Sintetico	Femminile
3	B	Sintetico	Maschile	A	Reale	Femminile
4	B	Reale	Maschile	A	Sintetico	Femminile
5	A	Sintetico	Femminile	B	Reale	Maschile
6	A	Reale	Femminile	B	Sintetico	Maschile
7	B	Sintetico	Femminile	A	Reale	Maschile
8	B	Reale	Femminile	A	Sintetico	Maschile
9	A	Sintetico	Maschile	B	Reale	Femminile
10	A	Reale	Maschile	B	Sintetico	Femminile
11	B	Sintetico	Maschile	A	Reale	Femminile
12	B	Reale	Maschile	A	Sintetico	Femminile
13	A	Sintetico	Femminile	B	Reale	Maschile
14	A	Reale	Femminile	B	Sintetico	Maschile
15	B	Sintetico	Femminile	A	Reale	Maschile
16	B	Reale	Femminile	A	Sintetico	Maschile

Tabella 1: Matrice sperimentale (ipotizzando un campione di 16 partecipanti)

- Tipo di Presentatore:
 - Reale (docente videoregistrato)
 - Sintetico (personaggio generato da AI)
- Genere del Presentatore:
 - Maschile
 - Femminile

Ogni possibile combinazione di assegnamenti di queste tre variabili rappresenta un possibile video che un partecipante può visionare. Ad esempio, un assegnamento del tipo:

$$Contenuto1 = A \wedge Tipo1 = Reale \wedge Genere1 = Maschile$$

rappresenta un video reale con un docente di genere maschile che espone il contenuto A. Sulla base di queste variabili andiamo a costruire una matrice sperimentale, ovvero una matrice che specifica, per ogni partecipante, il valore di ognuna di queste variabili per il primo e il secondo video che i partecipanti andranno a visionare durante

l'esperimento, specificando di conseguenza i due video che ogni partecipante andrà a visionare. Osserviamo che le tre variabili sono tutte e tre variabili binarie, ovvero possono assumere solo due valori. Questo ci permette di definire estremamente facilmente il vincolo che lega il primo e il secondo video: il secondo video sarà la negazione logica del primo, dove se *Contenuto1*, *Tipo1*, e *Genere1* sono le variabili che specificano il contenuto, il tipo e il genere del primo video, per il secondo video le variabili associate assumeranno rispettivamente i valori $\overline{\text{Contenuto1}}$, $\overline{\text{Tipo1}}$ e $\overline{\text{Genere1}}$. Per cui, ad esempio, sulla base dell'assegnamento indicato in precedenza, il secondo video sarebbe definito dai valori:

$$\text{Contenuto2} = B \wedge \text{Tipo2} = \text{Sintetico} \wedge \text{Genere2} = \text{Femminile}.$$

Per costruire la matrice è sufficiente esplicitare tutte le possibili combinazioni di assegnamenti di queste tre variabili per il primo video, e per ogni combinazione ricavare i rispettivi valori per il secondo video, utilizzando il vincolo appena definito. Esplicitando tutte le possibili combinazioni garantiamo che, con un campione abbastanza grande, tutti i casi possibili sono coperti e non vi sono combinazioni predominanti che potrebbero sbilanciare i dati raccolti. Osserviamo che le variabili sono tre, per cui il numero di possibili combinazioni è di $2^3 = 8$, per cui dopo 8 partecipanti la matrice si ripeterà, si tratta quindi di una matrice periodica. È possibile vedere un esempio di questa matrice in Tabella 1, dato un campione di 16 partecipanti. È possibile notare la periodicità della tabella, dove i valori delle variabili per i partecipanti da 1 a 8 sono ripetuti per i partecipanti da 9 a 16. Si osservi che non è importante la combinazione di partenza, posto che il campione sia abbastanza grande da coprire tutte le possibili combinazioni. Per stabilire la dimensione del campione, infine, è sufficiente stabilire quante volte si desidera coprire tutte le combinazioni, e scegliere una dimensione appropriata. Ad esempio, se si vuole coprire tutti i casi possibili almeno cinque volte, servirà un campione di almeno $5 \cdot 8 = 32$ partecipanti.

3.1.4 Variabili dipendenti

In un esperimento, una variabile dipendente è una variabile che viene osservata e misurata, per studiare l'effetto che variazioni alle variabili indipendenti hanno su tale variabile. Nel nostro caso, si tratta di ciò che ci aspettiamo possa essere influenzato in uno spettatore dalla natura sintetica di un video. Le variabili dipendenti identificate sono:

- Esperienza emotiva durante la lezione (misurata con questionari psicometrici post-sessione)
- Qualità dell'apprendimento (misurata con test di comprensione post-sessione)

- Fissazioni e movimento dello sguardo (misurati con eye-tracker)
- Frequenza cardiaca e livello di sudorazione (misurati tramite sensore sul polso)
- Espressioni emotive facciali (monitorate tramite registrazione della webcam).

Le ragioni a supporto delle prime due variabili dipendenti sono che: vogliamo misurare come l'utilizzo di video sintetici piuttosto che reali possa alterare l'esperienza emotiva e la qualità dell'apprendimento in uno studente. Questi sono due aspetti fondamentali da studiare, se la comprensione o il coinvolgimento emotivo vengono meno utilizzando video artificiali questo vanifica il senso di utilizzarli. Per poter misurare queste due variabili sono stati definiti dei questionari di autovalutazione emotiva, di valutazione e di apprendimento, da somministrare durante l'esperimento.

3.1.5 Definizione dei questionari

I questionari sono stati definiti dal professore Andrea Gaggioli del dipartimento di Psicologia dell'Università Cattolica del Sacro Cuore. Alcuni dei questionari sono stati definiti per questo studio, altri sono questionari noti all'interno del mondo della Psicologia come il Positive And Negative Affect Schedule (PANAS) [1], per la autovalutazione del proprio stato emotivo, e il Video Engagement Scale (VES) [8], per la valutazione del livello di coinvolgimento durante la visione di un video.

Questionari pre-trattamento

Sono stati specificati dei questionari pre-trattamento, da somministrare ai partecipanti all'inizio dell'esperimento, prima della visione di qualsiasi video. Qui vengono raccolti semplici dati demografici come l'età, il genere, la nazionalità e il livello di istruzione di ogni partecipante. In seguito, è somministrato un questionario di autovalutazione del loro stato emotivo pre-trattamento, seguito da una domanda (in una scala da 1 a 5) su quanto frequentemente il partecipante fa utilizzo di contenuti multimediali per l'apprendimento. Più nello specifico, i questionari pre-trattamento consistono in, in questo ordine:

- Dati demografici (età, genere, nazionalità, livello di istruzione, occupazione)
- Questionario per valutare lo stato emotivo iniziale (Positive and Negative Affect Schedule - PANAS), che misura l'umore momentaneo
- Scala sulla frequenza di utilizzo di contenuti video per l'apprendimento (ad es., lezioni online, tutorial, corsi su piattaforme digitali)
- Scala per misurare l'uso della tecnologia in generale a scopi educativi (16 item)

Il questionario su scala per misurare l'uso della tecnologia consiste in:

1. Frequenza di utilizzo della tecnologia:

- *Quanto spesso utilizzi tecnologie digitali (ad esempio, app, piattaforme, dispositivi) per scopi educativi?*
(Mai, Raramente, A volte, Spesso, Molto frequentemente)
- *Quanto spesso combini più tecnologie (ad esempio, video, quiz online, forum) nel tuo processo di apprendimento?*
(Mai, Raramente, A volte, Spesso, Molto frequentemente)

2. Tipi di tecnologie utilizzate:

- *Utilizzo piattaforme di gestione dell'apprendimento (ad esempio, Moodle, Blackboard, Google Classroom).*
(Mai, Raramente, A volte, Spesso, Molto frequentemente)
- *Utilizzo strumenti collaborativi (ad esempio, Microsoft Teams, Zoom, Google Docs) per scopi educativi.*
(Mai, Raramente, A volte, Spesso, Molto frequentemente)
- *Utilizzo app o piattaforme educative specializzate (ad esempio, Coursera, Khan Academy, Duolingo).*
(Mai, Raramente, A volte, Spesso, Molto frequentemente)

3. Scopi di utilizzo della tecnologia:

- *Utilizzo le tecnologie per accedere a materiali didattici (ad esempio, eBook, video, articoli).*
(Mai, Raramente, A volte, Spesso, Molto frequentemente)
- *Utilizzo le tecnologie per collaborare con i miei pari o con gli insegnanti/datori di lavoro.*
(Mai, Raramente, A volte, Spesso, Molto frequentemente)

4. Impatto percepito sull'apprendimento:

- *Usare la tecnologia migliora la mia comprensione del materiale.*
(Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)
- *La tecnologia mi aiuta a rimanere organizzato e a gestire meglio il mio apprendimento.*
(Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)

- *Apprendo meglio utilizzando le tecnologie rispetto ai metodi tradizionali.*
(Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)

5. Adattabilità e competenza:

- *Mi adatto rapidamente alle nuove tecnologie introdotte a scopi educativi.*
(Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)

6. Sfide e ostacoli:

- *A volte affronto difficoltà tecniche che ostacolano la mia esperienza di apprendimento.*
(Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)
- *L'accesso limitato a dispositivi o alla connessione internet influenza la mia capacità di usare la tecnologia per apprendere.*
(Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)

7. Coinvolgimento e motivazione:

- *La tecnologia rende l'apprendimento più coinvolgente per me.* (Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)
- *Mi sento motivato a esplorare nuovi argomenti o competenze quando utilizzo la tecnologia.*
(Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)

8. Integrazione nelle pratiche di apprendimento:

- *I miei insegnanti/datori di lavoro incoraggiano l'uso della tecnologia nel processo di apprendimento.*
(Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)
- *Integro regolarmente la tecnologia nella mia routine di studio.*
(Fortemente in disaccordo, In disaccordo, Né accordo né disaccordo, Accordo, Fortemente d'accordo)

Questionari post-video

Al termine della visione di ciascun video, viene poi somministrato un insieme di questionari. I questionari post-video consistono in un'autovalutazione del proprio stato emotivo in seguito alla visione, delle domande (in una scala da 1 a 5) sulla percezione della qualità dell'apprendimento e sulla valutazione del presentatore, un questionario sul livello di coinvolgimento durante la visione (Video Engagement Scale, o VES), e due domande sul livello di familiarità pregressa con l'argomento presentato e l'utilità percepita delle informazioni ricevute. Infine, è prevista una breve sessione di domande di comprensione a risposta multipla sui contenuti trattati nel video appena visionato, per misurare il grado di comprensione raggiunto. In un elenco puntato, i questionari post-video vengono presentati in questo ordine:

- Esperienza emotiva: Positive and Negative Affect Schedule (PANAS), per misurare i sentimenti positivi e negativi provati durante la videolezione
- Percezione della qualità dell'apprendimento:
 1. *"Quanto hai trovato chiari i contenuti della lezione?"* (scala da 1 a 5)
 2. *"Quanto sono stati facili da comprendere i concetti presentati nella lezione?"* (scala da 1 a 5)
 3. *"Quanto hai trovato ben organizzata la presentazione dei contenuti?"* (scala da 1 a 5)
 4. *"Quanto pensi di aver appreso dai contenuti presentati?"* (scala da 1 a 5)
 5. *"Quanto ti senti sicuro/a di ricordare le informazioni apprese nella lezione?"* (scala da 1 a 5)
 6. *"Quanto ti senti preparato/a ad applicare i concetti appresi?"* (scala da 1 a 5)
 7. *"Quanto ritieni utile la lezione per il tuo apprendimento?"* (scala da 1 a 5)
 8. *"Quanto la lezione ha stimolato il tuo interesse per l'argomento?"* (scala da 1 a 5)
 9. *"Quanto ti senti motivato/a a saperne di più sull'argomento dopo aver visto la lezione?"* (scala da 1 a 5)
- Valutazione del presentatore
 1. *"Come descriveresti il modo di presentare del relatore?"* (scala da 1 a 5, dove 1 è "Molto impersonale" e 5 è "Molto coinvolgente")

2. *"Quanto hai trovato efficace il relatore nella trasmissione dei contenuti?"*
(scala da 1 a 5)
 3. *"Quanto ti è sembrato chiaro e sicuro il relatore durante la spiegazione?"*
(scala da 1 a 5)
 4. *"Quanto ti sei sentito/a in sintonia con il relatore?"* (scala da 1 a 5)
 5. *"Quanto il presentatore ti è sembrato naturale e realistico nella presentazione dei contenuti?"* (scala da 1 a 5)
- Video Engagement Scale (VES)
 - Domande di familiarità e utilità
 1. *"Quanto eri già familiare o a conoscenza dei contenuti mostrati nel video?"*
(scala da 1 a 5)
 2. *"Quanto ti è sembrato utile e/o informativo questo contenuto?"*
(scala da 1 a 5)
 - Test di comprensione per valutare l'apprendimento oggettivo

I test di comprensione per valutare l'apprendimento oggettivo consistono in un quiz da 5 domande a crocette, con 1 risposta giusta e 3 risposte sbagliate, sui contenuti trattati.

3.1.6 Dati fisiologici, sguardo, espressioni facciali

Le altre tre variabili dipendenti sono meno ovvie, e richiedono una breve sezione sul perché è stato valutato importante misurarle, e in seguito come sono state misurate.

Dati fisiologici

Il nostro corpo è in uno stato di costante reazione agli stimoli proposti. Oltre a quello che percepiamo, valori come il battito cardiaco, il ritmo respiratorio, il livello di sudorazione della pelle sono fortemente influenzati dalle nostre emozioni e dagli stimoli visivi (e in particolar modo anche sonori [6]) che ci sono presentati [3]. A partire da questi è quindi possibile studiare le risposte emotive associate agli stimoli presentati, nel nostro caso i video reali o sintetici. Tra questi, il livello di sudorazione della pelle, detto anche Electrodermal Activity (EDA), è particolarmente utile, in quanto questo è fortemente collegato ai livelli di stress, tensione e reazione emotiva, specie durante l'apprendimento [2][7], e tende a essere fortemente reattivo.

Per la cattura dei dati fisiologici è stato predisposto un braccialetto Embrace Plus di Empatica Inc., indossato sul polso della mano non dominante di ogni partecipante.

Il braccialetto permette di misurare non intrusivamente i segnali che ci interessano, quali battito cardiaco e livello di sudorazione della pelle. Per assicurarsi una lettura accurata dei dati richiesti, ai partecipanti viene richiesto di indossare il braccialetto per 5-10 minuti prima dell'inizio dell'esperimento, affinché la pelle del partecipante possa abituarsi al contatto con il sensore, come indicato dai manuali d'uso di Empatica. Il braccialetto è configurato e abilitato via applicazione via smartphone, e i dati sono salvati su un server Amazon AWS, da cui è possibile scaricare offline in qualsiasi momento tutti i dati raccolti.

Eye-tracker

I motivi per cui è di nostro interesse misurare e tracciare il movimento dello sguardo sono molteplici: innanzitutto, vista la presenza di video realizzati tramite IA, questo ci permette di identificare eventuali elementi di distrazione che potrebbero essere presenti in tali video, dovuti a possibili artefatti o imperfezioni nei video generati. Vista la natura ancora in via di sviluppo di questa tecnologia, un dettaglio sul viso del presentatore, il movimento o l'aspetto delle mani, per fare qualche esempio, potrebbero essere elementi di distrazione¹. Inoltre, la misura delle fissazioni e del movimento dello sguardo possono essere ulteriori indicazioni del grado di coinvolgimento emotivo e del grado di attenzione dei partecipanti verso il video proposto [4][5].

Per il tracciamento dello sguardo e la misura delle fissazioni è utilizzato l'eye-tracker EyeLink 1000, di SR Research Ltd. Questo eye-tracker permette di ottenere, con un sample rate di fino a 1000 campioni al secondo, la posizione dello sguardo sullo schermo ad ogni istante e il diametro della pupilla. Per l'utilizzo dell'eye-tracker è prevista una fase di calibrazione, svolta manualmente da un operatore, insieme al partecipante, prima di avviare l'esperimento. In seguito, l'eye-tracker è pilotato dal computer che guida il partecipante attraverso l'esperimento, per cui il tracciamento e il salvataggio dei dati raccolti è automatico.

Espressioni facciali

Come trovato da [9][10], le espressioni facciali, e le relative emozioni, sono un buon indicatore del livello di interesse e coinvolgimento di uno studente durante l'apprendimento.

Per catturare le espressioni facciali, il partecipante viene registrato per tutta la durata dell'esperimento, previo consenso esplicito, tramite webcam, posta sullo schermo

¹Si osservi che non è necessariamente detto che queste distrazioni comportino un ostacolo nell'apprendimento, potrebbe evincersi dai risultati di questo studio che nonostante le fissazioni, dovessero essercene, i partecipanti non abbiano avuto problemi di comprensione. Questo arricchisce ancora di più l'importanza e l'utilità di questa variabile in questo studio

sul quale vengono visualizzati i video. In seguito, le espressioni facciali e le emozioni associate sono estratte dal video registrato utilizzando la libreria di python PyFeat.

3.1.7 Riepilogo

Per riepilogare, il disegno è di tipo *within-subjects*. Ciascun partecipante visiona due video didattici:

- Uno recitato da un docente maschio e uno da una docente femmina.
- Uno in versione reale (docente videoregistrato) e uno in versione sintetica (generato dall'AI).

Le variabili indipendenti sono:

- Tipo di contenuto:
 - Contenuto A
 - Contenuto B
- Tipo di Presentatore:
 - Reale (docente videoregistrato)
 - Sintetico (personaggio generato da AI)
- Genere del Presentatore:
 - Maschile
 - Femminile

Mentre le variabili dipendenti sono:

- Esperienza emotiva durante la lezione (misurata con questionari psicometrici post-sessione).
- Qualità dell'apprendimento (misurata con test di comprensione post-sessione).
- Eye tracking (misure di fissazione e sguardo).
- Frequenza cardiaca e sudorazione (misurate con braccialetto munito di sensore).
- Espressioni emotive facciali (analizzate tramite registrazione della webcam ed estratte con la libreria Python PyFeat).

Prima di cominciare, i partecipanti vengono accolti, e viene richiesta la firma del consenso informato sulla cattura di tutti dati sopra indicati. I partecipanti non sono informati della natura reale o sintetica dei personaggi nei video, per evitare bias sui dati raccolti. Prima di avviare l'esperimento, è prevista la preparazione delle misure fisiologiche:

- Battito cardiaco e sudorazione: Applicazione del braccialetto.
- Eye tracking: Calibrazione delle misure oculari.
- Espressioni facciali: Posizionamento della videocamera per il monitoraggio delle espressioni facciali.

Ogni partecipante visiona due video con contenuti diversi. Ciascun contenuto è presentato in una combinazione unica di caratteristiche: un contenuto sarà presentato da un docente maschile e l'altro da una docente femminile, uno sarà in versione reale e l'altro in versione sintetica. Il controbilanciamento copre anche l'ordine tra contenuto, genere e tipo di presentatore. Al termine, i partecipanti sono informati sui veri scopi dell'esperimento e sull'utilizzo dei dati raccolti.

3.2 Sviluppo dell'interfaccia

Per facilitare la fase di sperimentazione e raccolta dei dati è stato predisposto lo sviluppo di un'interfaccia, che guida il partecipante attraverso l'esperimento. L'interfaccia mostra i video previsti dal protocollo per tale partecipante, somministra i questionari definiti, e gestisce la cattura, il salvataggio e la sincronizzazione di tutti i segnali e i dati necessari, interfacciandosi con eye-tracker e braccialetto Empatica². L'interfaccia è stata sviluppata in Python, per mantenere il programma cross-platform, non essendo sicuri a monte del sistema operativo su cui si sarebbe fatto girare l'applicativo in fase di sperimentazione. L'interfaccia è stata sviluppata utilizzando la libreria di interfaccia grafica PyQt5. Il codice prodotto è reperibile al seguente link: <https://github.com/cosfederico/Interfaccia-Tesi/>.

3.2.1 Design di sviluppo

L'interfaccia è stata disegnata per essere controllata autonomamente dal partecipante. Una volta eseguita la calibrazione dell'eye-tracker (che deve essere svolta manualmente da un operatore), il partecipante è in grado di svolgere autonomamente l'esperimento, inserendo i propri dati e rispondendo alle domande proposte. Tutte le domande sono

²Insieme all'interfaccia è fornito uno script per il download automatico dei dati catturati dal braccialetto Empatica. Questo viene approfondito nel Paragrafo 3.3.4

poste su una scala da 1 a 5, o in modalità a risposta multipla per le domande di comprensione, per cui il partecipante ha bisogno solo del mouse per interagire con l'interfaccia. È stato molto importante rendere l'interfaccia compatibile a un utilizzo a una sola mano, poiché su uno dei due polsi del partecipante (il polso della mano non dominante) è indossato il braccialetto Empatica per la misura del battito cardiaco e il livello di sudorazione. È caldamente consigliato da Empatica evitare di muovere tale polso per ottenere i risultati più accurati, per questo motivo è stata fatta tale scelta di design.

3.2.2 Avvio dell'esperimento

L'interfaccia è stata arricchita di alcune funzionalità a supporto dello sperimentatore. Prima di cominciare con l'esperimento, viene aperta una finestra di preparazione, dove è possibile selezionare tra tutte le webcam attive sul sistema quale utilizzare per la registrazione del video, ed è presente un pulsante per effettuare una prova del sistema audio, per assicurarsi di avere selezionato l'uscita audio corretta (Figura 1a). A seguire, è visualizzata una finestra di anteprima della webcam selezionata. In sovrapposizione all'anteprima della webcam è posta una figura stilizzata per indicare il posizionamento ottimale della persona e del volto nell'inquadratura, per l'analisi ottimale delle espressioni facciali (Figura 1b). Terminata la fase di preparazione, viene lanciato il programma principale, dove il partecipante è accolto nella schermata di introduzione (Figura 2), dove è informato sui dettagli dell'esperimento, quali durata dei video e dell'esperimento, dati e segnali raccolti, e accorgimenti sull'utilizzo del mouse. Qui, il partecipante ha la possibilità di esprimere il suo consenso informato, tramite checkbox, e avviare l'esperimento, altrimenti uscire e abbandonare l'esperimento. L'avvio della registrazione di tutti i dati e segnali avviene solo una volta che il partecipante ha espresso il suo consenso e premuto il pulsante "Inizia". A partire da quel momento, l'esperimento è ufficialmente iniziato.

3.2.3 Raccolta dei timestamp

L'interfaccia tiene traccia di tutti i timestamp degli eventi principali, per permettere la sincronizzazione dei dati e dei segnali raccolti, e per poter associare i dati agli eventi di interazione del partecipante con l'interfaccia. Tutta l'interfaccia è stata disegnata a pagine: ogni volta che il partecipante passa alla pagina successiva viene salvato il timestamp di tale evento. In questo modo, sono salvati i timestamp di inizio sessione, fine sessione, inizio e fine di ogni video visualizzato, e i timestamp di risposta ad ogni domanda dei questionari presentati. I questionari sono stati disegnati in modo



Figura 1: Schermate di preparazione dell'interfaccia sviluppata: (a) Schermata di selezione della webcam. (b) Schermata di anteprima della webcam, con figura in sovra-impressione per il posizionamento ottimale del volto.

da presentare una domanda alla volta per pagina³: quando il partecipante passa alla domanda successiva, viene salvato il timestamp di tale evento. Questo ci permette non solo di sapere quando il partecipante è passato alla domanda successiva, ma anche quanto tempo ha impiegato per rispondere alla domanda proposta, sottraendo il timestamp salvato con il precedente. Trattandosi di domande a risposta chiusa (da 1 a 5, o a risposta multipla) non è un problema considerare il tempo di digitazione della risposta, in quanto per rispondere basta un click. I timestamp sono salvati in UNIX-time, rispetto al fuso orario UTC (Coordinated Universal Time).

3.2.4 Registrazione della webcam/dello schermo

Durante tutta la durata dell'esperimento, l'interfaccia si occupa della registrazione della webcam selezionata per l'estrazione delle espressioni facciali, e della registrazione dello schermo. La registrazione del volto è effettuata tramite una webcam esterna, posta sotto al monitor sul quale sono presentati gli stimoli. In fase di avvio dell'interfaccia è mostrata allo sperimentatore una schermata con le istruzioni necessarie per il posizionamento ottimale della webcam. La registrazione dello schermo è necessaria per l'utilizzo dei dati di eye-tracking, in quanto rappresenta gli stimoli presentati. Combinando i dati di eye-tracking e la registrazione dello schermo è possibile analizzare il movimento dello sguardo e le fissazioni, associando ad ogni sguardo e fissazione lo stimolo sullo schermo che lo ha stimolato.

³Fatta eccezione per il questionario di autovalutazione dello stato emotivo (Positive and Negative Affect Schedule, PANAS), il quale è presentato in una pagina sola, e di questo è salvato solo il timestamp di inizio e fine di tutto il questionario.



Figura 2: Schermata di benvenuto dell'interfaccia sviluppata.

Le registrazioni sono eseguite su due processi paralleli al processo principale di generazione della GUI. Questo permette di non rallentare l'interfaccia grafica e permette una registrazione di entrambi i video più fluida, riducendo di molto il rischio di fotogrammi persi.

3.2.5 Controllo dell'eye-tracker

L'interfaccia si occupa anche del controllo dell'eye-tracker, e quindi dell'acquisizione e del salvataggio dei dati di eye-tracking. Il sistema di eye-tracking è collegato direttamente al computer che dirige l'esperimento, tramite cavo Ethernet. Research SR, il fornitore dell'eye-tracker, fornisce una libreria di API in Python per il controllo via codice dell'eye-tracker, attraverso il quale è controllato dall'interfaccia.

A inizio esperimento, l'interfaccia effettua il collegamento con l'eye-tracker e avvia la procedura di calibrazione. La calibrazione è svolta manualmente dallo sperimentatore, il quale guida il partecipante attraverso il processo, e, dovesse essere necessario, può rieseguire la calibrazione fino ad ottenere dei risultati abbastanza buoni per una buon tracciamento dello sguardo. Quando la calibrazione è conclusa, il controllo torna all'interfaccia, da dove il partecipante può far iniziare l'esperimento.

Quando il partecipante preme il pulsante per iniziare l'esperimento, l'interfaccia avvia la cattura dei dati di eye-tracking, gestendo il salvataggio del timestamp di

inizio cattura, per permettere poi la sincronizzazione dei dati di eye-tracking con tutti gli altri dati.

3.3 Salvataggio dei dati raccolti

In questa sezione andiamo ad analizzare brevemente come tutti i dati raccolti dall'interfaccia vengono salvati, per essere poi pronti per la fase di analisi.

3.3.1 Salvataggio dei dati demografici e delle risposte

I dati misti catturati dall'interfaccia, quali i dati demografici del partecipante (età, genere, nazionalità, livello di istruzione), le risposte ai questionari, e tutti i timestamp registrati, sono salvati in un formato `.csv`. Il file `.csv` presenta una sola riga, con campi:

- ID del partecipante
- Dati demografici (età, genere, nazionalità, livello di istruzione)
- Timestamp di inizio, fine sessione
- Timestamp di inizio, fine video, natura e genere dei video mostrati
- Per ogni domanda la risposta selezionata e la domanda associata + timestamp
- Risposte ai questionari PANAS, con punteggio ottenuto + timestamp
- Risposte alle domande a risposta multipla, salvando la domanda chiesta, la risposta segnata, e se questa era corretta o meno + timestamp.

3.3.2 Salvataggio delle registrazioni video

Per l'estrazione delle espressioni facciali (registrazione della webcam) e l'analisi degli stimoli visivi (registrazione dello schermo) non è necessario l'utilizzo del segnale RAW della webcam, per cui le registrazioni sono salvate in formato `.mp4` compresso, per ridurre lo spazio richiesto per memorizzare i dati salvati.

3.3.3 Salvataggio dei dati di eye-tracking

Come già detto, il sistema di eye-tracking è controllato internamente dall'interfaccia, utilizzando le API fornite da SR Research. A fine esperimento, l'interfaccia si occupa di interrompere l'acquisizione dei dati di eye-tracking e scaricare i dati registrati. I

dati sono trasferiti via Ethernet, e sono scaricati in un formato proprietario (`.edf`, Eyelink Data Format), ma Research SR fornisce un programma da linea di comando per convertire tale formato in formato di testo (`.txt`). L'interfaccia si occupa quindi di scaricare i dati e convertirli in formato `.txt`. Il file `.txt` prodotto presenta una riga per campione, con posizione x, y dello sguardo sullo schermo, e diametro della pupilla, in numero di pixel. Per l'analisi dei dati è stato sviluppato uno script per la conversione dei dati dal formato `.txt` al formato `.csv`. Nel Capitolo !!AGGIUNGI REF!! verrà approfondito come questi dati sono utilizzati e come il diametro della pupilla è convertito da numero di pixel in *cm*.

3.3.4 Salvataggio dei dati fisiologici

Il salvataggio dei dati fisiologici richiede maggiore attenzione. Come anticipato, il bracciale Empatica non è collegato direttamente all'interfaccia, ma è bensì controllato tramite applicazione via smartphone. In realtà, è leggermente più complesso.

Empatica mette a disposizione per tutti i suoi clienti un portale online (<https://auth.carelab.empatica.com/>). Dal portale è necessario creare un "Partecipante": un partecipante è una coppia univoca di credenziali (username e password). Una volta scaricata l'applicazione CareLab su smartphone (disponibile sia su Android che iOS), si utilizzano queste credenziali appena generate per effettuare il login sull'app. Questa operazione di login è ciò che permette al telefono di collegarsi all'orologio, e così l'orologio inizia immediatamente a registrare tutti i dati fisiologici, e a sincronizzarli sul telefono. La registrazione dei dati è quindi asincrona: l'orologio non è collegato all'interfaccia⁴. Una volta terminato l'esperimento, è presente sull'app un pulsante per terminare la cattura, il quale trasferisce i dati non ancora sincronizzati, li carica sul cloud online, e spegne l'orologio.

I dati sono salvati su un server Amazon AWS dedicato ai propri prodotti di Empatica. Sul portale CareLab sono presenti le credenziali per accedere al server AWS e scaricare i dati. Questa soluzione è stata valutata come molto utile, in quanto, posto che l'orologio sia stato configurato correttamente, il salvataggio dei dati è automatico, e i dati sono scaricabili in qualsiasi momento, non dovendosene preoccupare durante la sperimentazione.

Per scaricare i dati è stato sviluppato uno script in Python, che utilizzando l'ID del partecipante, l'ora dell'acquisizione e i dati di login al server AWS, scarica automaticamente i dati associati alla acquisizione e li sincronizza con la cattura, ritagliando i dati che ci servono. Questa operazione verrà approfondita nel Capitolo !!AGGIUNGI REF!! sull'elaborazione dei segnali. Lo script si occupa anche di selezionare i segnali

⁴Per questo motivo, è importante che la cattura dei dati fisiologici sia avviata e terminata manualmente rispettivamente prima e dopo che l'esperimento sia iniziato, così da permettere di sincronizzarli con i dati dell'interfaccia.

che si vogliono scaricare. Il braccialetto Empatica è in grado di catturare un gran numero di segnali, ovvero:

- Accelerometro (x, y, z)
- Giroscopio (x, y, z)
- Temperatura della pelle ($^{\circ}\text{C}$)
- ElectroDermal Activity (μS)
- Passi
- Blood Volume Pulse (BVP) ($n\text{W}$)
- Systolic Peaks.

Il braccialetto produce anche una serie di segnali aggregati, segnali come battito cardiaco o il ritmo respiratorio, ma questi segnali sono aggregati per minuto, ovvero vi è un campione ogni minuto. Questo rende l'utilizzo di questi dati aggregati inutile per la nostra ricerca, la quale richiede una precisione più fine. Tra questi dati vengono scaricati i dati di picchi sistolici (systolic peaks), per il battito cardiaco, e il livello di sudorazione della pelle (ElectroDermal Activity, o EDA). È inoltre scaricato anche il segnale di BVP (volume di pressione nel sangue), il quale è sempre associato al battito cardiaco, e potrebbe tornare utile in fase di analisi. Nel Capitolo !!AGGIUNGI REF!! verrà approfondita l'analisi di questi segnali, e come i systolic peaks vengono utilizzati per ricostruire il segnale di battito cardiaco in forma non aggregata.

Capitolo 4

Analisi dei dati acquisiti

Conclusioni

Bibliografia

- [1] John R Crawford and Julie D Henry. The positive and negative affect schedule (panas): Construct validity, measurement properties and normative data in a large non-clinical sample. *British journal of clinical psychology*, 43(3):245–265, 2004.
- [2] Elena Di Lascio, Shkurta Gashi, and Silvia Santini. Unobtrusive assessment of students’ emotional engagement during lectures using electrodermal activity sensors. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 2(3):1–21, 2018.
- [3] Nadeesha M Gunaratne, Claudia Gonzalez Viejo, Thejani M Gunaratne, Damir D Torrico, Hollis Ashman, Frank R Dunshea, and Sigfredo Fuentes. Effects of imagery as visual stimuli on the physiological and emotional responses. *J*, 2(2):206–225, 2019.
- [4] Pragma Kar, Samiran Chattopadhyay, and Sandip Chakraborty. Gestatten: Estimation of user’s attention in mobile moocs from eye gaze and gaze gesture tracking. *Proceedings of the ACM on Human-Computer Interaction*, 4(EICS):1–32, 2020.
- [5] Shengxi Liu, Xiaomei Tao, and Qiong Gui. Research on emotional state in online learning by eye tracking technology. In *Proceedings of the 4th international conference on intelligent information processing*, pages 471–477, 2019.
- [6] Amy Pitchforth. *Emotional response to auditory and visual stimuli*. Loma Linda University, 2010.
- [7] Angelica M Tinga, Tycho T De Back, and Max M Louwerse. Non-invasive neurophysiology in learning and training: mechanisms and a swot analysis. *Frontiers in neuroscience*, 14:589, 2020.
- [8] Leonie NC Visser, Marij A Hillen, Mathilde GE Verdam, Nadine Bol, Hanneke CJM de Haes, and Ellen MA Smets. Assessing engagement while viewing video

- vignettes; validation of the video engagement scale (ves). *Patient Education and Counseling*, 99(2):227–235, 2016.
- [9] Jacob Whitehill, Zewelanji Serpell, Yi-Ching Lin, Aysha Foster, and Javier R Movellan. The faces of engagement: Automatic recognition of student engagement from facial expressions. *IEEE Transactions on Affective Computing*, 5(1):86–98, 2014.
- [10] Zhaoli Zhang, Zhenhua Li, Hai Liu, Taihe Cao, and Sannyuya Liu. Data-driven online learning engagement detection via facial expression and mouse behavior recognition technology. *Journal of Educational Computing Research*, 58(1):63–86, 2020.

Ringraziamenti